

数值分析基础知识清单(必背)

- 设 x 为准确值, x^* 为近似值, 则 $e := x - x^*$ 称作近似值 x^* 的 **(绝对)误差**, 若 $x^* \neq 0$, 则 $e_r^* := e/x^*$ 称作 x^* 的**相对误差**, 使得 $|e| \leq \varepsilon$ 的 ε 称作 x^* 的 **(绝对)误差限**, 使得 $|e_r^*| \leq \varepsilon$ 的 ε 称作 x^* 的**相对误差限**.
- **有效数字**. 设 x 的近似值 $x^* = \pm 0.a_1a_2 \cdots a_n \times 10^m, m \in \mathbb{Z}, a_1 \neq 0$, 则 x^* 具有 n 位有效数字 $\iff |x - x^*| \leq \frac{1}{2} \times 10^{m-n}$, 此时 $\varepsilon = \frac{1}{2} \times 10^{m-n}$ 为 x^* 的一绝对误差限, 并且其相对误差限满足 $\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-(n-1)}$; 反之, 若 x^* 的相对误差限满足 $\varepsilon_r \leq \frac{1}{2(a_1+1)} \times 10^{-(n-1)}$, 则 x^* 具有 n 位有效数字.
- 数值计算的若干原则:
 - (1) 保障算法的收敛性和稳定性;
 - (2) 避免绝对值很小的数作除数;
 - (3) **避免两相近的数相减**;
 - (4) 防止大数"吃掉"小数;
 - (5) 简化计算步骤, 减少运算次数.下面列举几例阐明(3).

避免两相近的数相减.

(1) 求 $ax^2 + bx + c = 0 (a \neq 0)$ 的根, 采用 $x_1 = -\frac{b + \operatorname{sgn}(b)\sqrt{b^2 - 4ac}}{2a}, x_2 = \frac{c}{ax_1}$ 的方法;

(2) 适当作等价变形, 例如

$$\sqrt{x + \frac{1}{x}} - \sqrt{x - \frac{1}{x}} (x \gg 1) = \frac{\sqrt{x^2+1} - \sqrt{x^2-1}}{\sqrt{x}} = \frac{2}{\sqrt{x}(\sqrt{x+1/x} + \sqrt{x-1/x})}.$$

• 非线性方程求解.

◦ **1 二分法**. 基本的内容, 自己看课本.

◦ **2 迭代法**. 牢记 **(掌握证明)** 不动点迭代的两个收敛定理. 迭代方程为

$$x_{n+1} = \varphi(x_n).$$

- **全局收敛性**. 设 φ' 在 $[a, b]$ 上存在, 且 $\varphi([a, b]) \subseteq [a, b], \exists L \in (0, 1)$, 满足 $\sup_{x \in [a, b]} |\varphi'(x)| \leq L < 1$, 则 $x = \varphi(x)$ 在 $[a, b]$ 上有唯一解 x^* , 对任意初值 $x_0 \in [a, b], x_{n+1} = \varphi(x_n)$ 产生的迭代序列 $\{x_n\}$ 收敛到 x^* .
- **局部收敛性**. 在 $x = \varphi(x)$ 之根 x^* 的某邻域 R 内 φ' 存在, 且 $\exists L \in (0, 1)$, 满足 $\sup_{x \in R} |\varphi'(x)| \leq L < 1$, 则任取 $x_0 \in R$, 迭代格式 $x_{n+1} = \varphi(x_n)$ 均收敛于 x^* , 且有误差估计

$$|x^* - x_k| \leq \frac{L}{1-L} |x_k - x_{k-1}|, \quad |x^* - x_k| \leq \frac{L^k}{1-L} |x_1 - x_0|;$$

反之, 若 x^* 的邻域 R 内 $|\varphi'(x)| \geq 1$, 则迭代格式发散.

- **收敛阶.** 设迭代 $x_{k+1} = \varphi(x_k)$ 收敛到不动点 x_* . 记 $e_k := x_k - x_*$, 若

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = c,$$

其中 $p \geq 1$, 常数 c 与 k 无关, 则称该迭代是 p **阶收敛** 的.

- 若 $p = 1$ 且 $0 < c < 1$, 则称**线性收敛**;
- 若 $p = 2$, 则称**二次收敛**或**平方收敛**;
- 若 $1 < p < 2$ 或 $p = 1$ 且 $c = 0$, 则称**超线性收敛**.
- **收敛阶的判定.** 设 x_* 是 $\varphi(x)$ 的不动点且 $p \geq 2$ 是正整数. 若 $\varphi^{(p)}(x)$ 在 x_* 的某个邻域内连续且

$$\varphi'(x_*) = \varphi''(x_*) = \cdots = \varphi^{(p-1)}(x_*) = 0, \quad \varphi^{(p)}(x_*) \neq 0,$$

则不动点迭代 $x_{k+1} = \varphi(x_k)$ 是 p 阶局部收敛的, 且有

$$\lim_{k \rightarrow \infty} \frac{x_{k+1} - x_*}{(x_k - x_*)^p} = \frac{\varphi^{(p)}(x_*)}{p!}.$$

举例明之: 见教材23页例4.

。 3 Newton迭代.

$$\left\{ \begin{array}{l} \text{单根}(\varphi''(x^*) \neq 0), \text{迭代格式为 } x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \text{局部二阶收敛;} \\ \text{重根}(\varphi''(x^*) = 0) \left\{ \begin{array}{l} \text{仍然使用Newton迭代法, 此时是局部线性收敛;} \\ \text{改进1: 迭代格式为 } x_{k+1} = x_k - \frac{f(x_k)f'(x_k)}{[f'(x_k)]^2 - f(x_k)f''(x_k)}, \text{局部二阶收敛;} \\ \text{改进2: 迭代格式为 } x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}, m \text{ 为已知根的重数;} \\ \text{此时局部二阶收敛.} \end{array} \right. \end{array} \right.$$

- Newton迭代法的变形.

- 用常数 M 代替 $f'(x_k)$, 若在 x^* 附近, 有 $0 < \frac{f'(x)}{M} < 2$, 则

$$x_{k+1} = x_k - \frac{f(x_k)}{M} \text{ 局部线性收敛. 通常取 } M = f'(x_k).$$

- 用 $\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 代替 $f'(x_k)$, 得到迭代公式

$$x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1}), \text{收敛阶为 } \frac{1+\sqrt{5}}{2}, \text{称之为} \mathbf{双点割线法};$$

- 用 $\frac{f(x_k) - f(x_0)}{x_k - x_0}$ 代替 $f'(x_k)$, 得到迭代公式

$$x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_0)}(x_k - x_0),$$
 局部线性收敛, 称之为**单点割线法**.

- 解非线性方程的Newton法. 令

$\mathbf{x}_k = (x_k, y_k)^\top$, $\mathbf{f}(\mathbf{x}_k) = (f_1(x_k, y_k), f_2(x_k, y_k))^\top$, $\mathbf{f}'(\mathbf{x}_k)$ 为Jacobi矩阵, 则Newton迭代格式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\mathbf{f}'(\mathbf{x}_k)]^{-1} \mathbf{f}(\mathbf{x}_k) \iff \mathbf{f}'(\mathbf{x}_k)(\mathbf{x}_{k+1} - \mathbf{x}_k) = -\mathbf{f}(\mathbf{x}_k).$$

其分量形式为

$$\begin{cases} \frac{\partial}{\partial x} f_1(x_k, y_k)(x_{k+1} - x_k) + \frac{\partial}{\partial y} f_1(x_k, y_k)(y_{k+1} - y_k) = -f_1(x_k, y_k), \\ \frac{\partial}{\partial x} f_2(x_k, y_k)(x_{k+1} - x_k) + \frac{\partial}{\partial y} f_2(x_k, y_k)(y_{k+1} - y_k) = -f_2(x_k, y_k). \end{cases}$$

• 线性方程组解法.

- 向量范数和矩阵范数. 记 $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$, $\mathbf{A} = (a_{ij})_{n \times n}$, 则

- $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$, $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$, $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$.
- $\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ = 行的绝对值的和的最大值;
- $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ = 列的绝对值的和的最大值;
- $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$;
- 矩阵 $\mathbf{A}$ 的条件数为 $\text{cond}(\mathbf{A}) := \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$. 设 $\mathbf{A}$ 非异, $\mathbf{x}$ 是方程组 $\mathbf{Ax} = \mathbf{b}$ 的准确解, $\tilde{\mathbf{x}}$ 是其近似解, $\mathbf{r} = \mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}$, 则

$$\frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \text{cond}(\mathbf{A}) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}.$$

- Gauss顺序消去法

- 需要计算 $\frac{1}{3}n^3 + n^2 - \frac{1}{3}n$ 次乘法;
- 成立的充要条件是系数矩阵的顺序主子式非零;
- 与LU分解等价;
- **列主元素消去法**: 在消元的第 k 步, 首先在第 k 列下方所有元素中取绝对值为最大者为主元, 并交换到第 k 行. 举例明之:

用Gauss消去法和列主元消去法求解线性方程组

$$\begin{bmatrix} 1 & 2 & 1 \\ -2 & -4 & 3 \\ -1 & 3 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}.$$

解. 先用Gauss消去法:

$$\left[\begin{array}{ccc|c} 1 & 2 & 1 & 2 \\ -2 & -4 & 3 & 1 \\ -1 & 3 & 1 & 0 \end{array} \right] \xrightarrow[r_3+r_1]{r_2+2r_1} \left[\begin{array}{ccc|c} 1 & 2 & 1 & 2 \\ 0 & 0 & 5 & 5 \\ 0 & 5 & 2 & 2 \end{array} \right]$$

进行到第2个方程为主方程时, 主元 $a_{22}^{(1)} = 0$, 顺序消去法无法进行. **算法失败.** 下面用列主元消去法求解:

$$\begin{aligned} \left[\begin{array}{ccc|c} 1 & 2 & 1 & 2 \\ -2 & -4 & 3 & 1 \\ -1 & 3 & 1 & 0 \end{array} \right] &\xrightarrow{r_1 \leftrightarrow r_2} \left[\begin{array}{ccc|c} -2 & -4 & 3 & 1 \\ 1 & 2 & 1 & 2 \\ -1 & 3 & 1 & 0 \end{array} \right] \\ &\xrightarrow[r_3 - \frac{1}{2}r_1]{r_2 + \frac{1}{2}r_1} \left[\begin{array}{ccc|c} -2 & -4 & 3 & 1 \\ 0 & 0 & \frac{5}{2} & \frac{5}{2} \\ 0 & 5 & -\frac{1}{2} & -\frac{1}{2} \end{array} \right] \\ &\xrightarrow{r_2 \leftrightarrow r_3} \left[\begin{array}{ccc|c} -2 & -4 & 3 & 1 \\ 0 & 5 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & 0 & \frac{5}{2} & \frac{5}{2} \end{array} \right], \end{aligned}$$

逐个回代得到 $x_1 = 1, x_2 = 0, x_3 = 1$. $\square$

• LU分解

- 求LU分解的紧凑格式: $\mathbf{A} = \mathbf{LU}$, 其中 $\mathbf{A} = (a_{ij})_{n \times n}$, $\mathbf{L} = (l_{ij})_{n \times n} (l_{ii} = 1, l_{ij} = 0 \text{ 当 } i < j)$, $\mathbf{U} = (u_{ij})_{n \times n} (u_{ij} = 0 \text{ 当 } i > j)$. 递推公式为

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}, \quad l_{ij} = \frac{1}{u_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj} \right).$$

- 举例明之, 设 $\mathbf{A} = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$, 使用紧凑格式求解 $\mathbf{A}$ 的LU分解步骤为

$$\begin{pmatrix} 2 & 1 & 1 \\ 4 & & \\ 8 & & \end{pmatrix} \rightarrow \begin{pmatrix} 2 & 1 & 1 \\ 2 & & \\ 4 & & \end{pmatrix} \rightarrow \begin{pmatrix} 2 & 1 & 1 \\ 2 & 1 & 1 \\ 4 & 7 & 9 \end{pmatrix} \rightarrow \begin{pmatrix} 2 & 1 & 1 \\ 2 & 1 & 1 \\ 4 & 3 & 9 \end{pmatrix} \rightarrow \begin{pmatrix} 2 & 1 & 1 \\ 2 & 1 & 1 \\ 4 & 3 & 2 \end{pmatrix},$$

从而

$$\mathbf{U} = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}, \quad \mathbf{L} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}. \quad \square$$

- 对于一般的三阶矩阵的LU分解,

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ a_{21}/a_{11} & 1 & 0 \\ a_{31}/a_{11} & l_{32} & 1 \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{pmatrix}.$$

下面再逐个计算 $u_{22}, u_{23}, l_{32}, u_{33}$.

- $u_{22} = a_{22} - \frac{a_{21}a_{12}}{a_{11}};$
- $u_{23} = a_{23} - \frac{a_{21}a_{13}}{a_{11}};$
- $l_{32} = \frac{a_{32} - \frac{a_{31}a_{12}}{a_{11}}}{u_{22}};$
- $u_{33} = a_{33} - \frac{a_{31}a_{13}}{a_{11}} - l_{32}u_{23}.$

- Cholesky分解

- Cholesky分解是指 $\mathbf{A} = \mathbf{LDL}^\top$, $\mathbf{L}$ 是**单位下三角矩阵** (主对角线元素全为1), $\mathbf{D}$ 是**对角矩阵**. 计算的递推公式为

$$d_j = a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 d_k, \quad l_{ij} = \frac{1}{d_j} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} \right) \quad (i > j).$$

- 设矩阵 $\mathbf{A}$ 对称正定, 则必存在单位下三角阵 $\mathbf{L}$ 以及对角阵 $\mathbf{D}$, 使得 $\mathbf{A} = \mathbf{LDL}^\top$.

- 迭代法

- 对于迭代格式 $\mathbf{x}^{(k+1)} = \mathbf{M}\mathbf{x}^{(k)} + \mathbf{g}$, 给定任何初始向量 $\mathbf{x}^{(0)}$ 和常数向量 $\mathbf{g}$, 其收敛的充分必要条件为 $\rho(\mathbf{M}) = \max_{1 \leq i \leq n} |\lambda_i| < 1$.
- 下面设 $\mathbf{A} = (a_{ij})_{n \times n}$, $\mathbf{b} = (b_1, b_2, \dots, b_n)^\top$.
 - Jacobi迭代法的分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(- \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i \right),$$

矩阵形式为 $\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}$, 其中 $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$.

- 若 $\mathbf{A}$ 或 $\mathbf{A}^\top$ 严格对角占优, 则Jacobi迭代法收敛.

- Gauss-Seidel迭代法的分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(- \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i \right),$$

矩阵形式为 $\mathbf{x}^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{U} \mathbf{x}^{(k)} + (\mathbf{D} - \mathbf{L})^{-1} \mathbf{b}$, 其中 $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$.

- 若 $\mathbf{A}$ 或 $\mathbf{A}^\top$ 严格对角占优, 则 Gauss-Seidel 迭代法收敛.
- 若 $\mathbf{A}$ 对称正定, 则 Gauss-Seidel 迭代法收敛.

- SOR迭代法的分量形式为

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left(- \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} + b_i \right),$$

其中 $\omega > 0$ 为松弛因子, $\omega > 1$, $\omega < 1$, $\omega = 1$ 时分别称作逐次超松弛迭代法, 逐次低松弛迭代法, Gauss-Seidel 迭代法. SOR 迭代法的矩阵形式为

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \omega \mathbf{L})^{-1} [(1 - \omega) \mathbf{D} + \omega \mathbf{U}] \mathbf{x}^{(k)} + \omega (\mathbf{D} - \omega \mathbf{L})^{-1} \mathbf{b}.$$

- SOR 迭代法收敛的必要条件为 $0 < \omega < 2$.
- 若 $\mathbf{A}$ 对称正定, 则 SOR 迭代法收敛的充分必要条件是 $\omega \in (0, 2)$.

• 插值法

- Lagrange 插值.

- 给定 $(x_i, f(x_i)) (i = 0, 1, 2, \dots, n)$, 则次数不超过 n 的满足 $P_n(x_i) = y_i (i = 0, 1, \dots, n)$ 的多项式 P_n 存在且唯一, 其基函数为 $l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}$, 此时 $P_n = \sum_{i=0}^n y_i l_i$. 插值余项为

$$R_n(x) := f(x) - P_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i), \quad \xi_x \in (a, b).$$

证明方法需要掌握. 简言之, 构造常数 $K(x) := \frac{f(x) - P_n(x)}{\prod_{i=0}^n (x - x_i)}$, 并置

$$\varphi(t) := f(t) - P_n(t) - K(t) \prod_{i=0}^n (t - x_i),$$

然后反复使用 Rolle 定理.

- 插值多项式的性质.

$$1. \sum_{i=0}^n l_i(x) = 1. \text{ Proof 取 } f \equiv 1, \text{ 则由插值多项式的唯一性}(f \equiv 1 \text{ 本身}$$

就是一个满足条件的插值多项式)知命题成立. $\square$

$$2. \sum_{i=0}^n x_i^j l_i(x) = x^j, j = 1, 2, \dots, n. \text{ Proof 取 } f(x) \equiv x^j, j \in \{1, \dots, n\},$$

则由插值多项式的唯一性($f(x) \equiv x^j$ 本身就是一个满足条件的插值多项式)知命题成立. $\square$

$$3. \sum_{i=0}^n (x_i - x)^j l_i(x) = 0, j = 1, 2, \dots, n. \text{ Proof 由二项式定理并交换}$$

求和次序有

$$\begin{aligned} \sum_{i=0}^n (x_i - x)^j l_i(x) &= \sum_{i=0}^n \left[\sum_{k=0}^j \binom{j}{k} x_i^k (-x)^{j-k} \right] l_i(x) \\ &= \sum_{k=0}^j \binom{j}{k} (-x)^{j-k} \cdot \sum_{i=0}^n x_i^k l_i(x) \end{aligned}$$

由结论(1)(2), 对任意 $k \leq j \leq n$, 有 $\sum_{i=0}^n x_i^k l_i(x) = x^k$, 代入得:

$$\sum_{k=0}^j \binom{j}{k} (-x)^{j-k} x^k = (x - x)^j = 0^j = 0 \quad (j \geq 1).$$

故原等式成立. $\square$

$$4. \sum_{i=0}^n l_i(0) x_i^j = \begin{cases} 1, & j = 0, \\ 0, & j = 1, 2, \dots, n, \\ (-1)^n x_0 x_1 \cdots x_n, & j = n + 1. \end{cases} \text{ Proof 当 } j = 0 \text{ 时}$$

由(1)即得. 当 $j = 1, 2, \dots, n$, 在(3)中取 $x = 0$ 即得. 当 $j = n + 1$ 取 $n + 1$ 次多项式 $f(x) = x^{n+1}$, 其 n 次Lagrange插值多项式为:

$$L_n(x) = \sum_{i=0}^n x_i^{n+1} l_i(x),$$

根据Lagrange插值余项公式:

$$f(x) - L_n(x) = x^{n+1} - \sum_{i=0}^n x_i^{n+1} l_i(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^n (x - x_k) = \prod_{k=0}^n (x -$$

令 $x = 0$ 即得. $\square$

- 插值点 x 距离插值节点 x_i 较远时, 效果可能较差, 通常采用基本插值区间 $[\min_{0 \leq i \leq n} x_i, \max_{0 \leq i \leq n} x_i]$. (例如114页第3题这种)

- 若有 $\max_{a \leq x \leq b} |f^{(n+1)}(x)| = M_{n+1}$, 则有余项估计

$$|R_n(x)| \leq \frac{M_{n+1}}{(n+1)!} \left| \prod_{i=0}^n (x - x_i) \right|.$$

Lagrange插值不一定收敛! 经典Runge现象, 考虑

$f: [-1, 1] \rightarrow \mathbb{R}, f(x) := \frac{1}{1+25x^2}$, 取等距节点.

◦ Newton插值公式

- 差商可表示为函数值的线性组合, 即

$$f[x_0, \dots, x_n] = \sum_{k=0}^n a_k f(x_k), \quad a_k = \frac{1}{\prod_{\substack{j=0 \\ j \neq k}}^n (x_k - x_j)}.$$

从而差商与节点的排列次序无关.

- $f[x_0, x_1, \dots, x_n] = \frac{f[x_1, \dots, x_n] - f[x_0, \dots, x_{n-1}]}{x_n - x_0}$.
- 若 f 在 $[a, b]$ 上存在 n 阶导数, 且 $\{x_i\}_{i=0}^n \subseteq [a, b]$, 则 $\exists \xi \in [a, b]$, 使得

$$f[x_0, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}. \text{ 特别地, 若 } f(x) = \sum_{i=0}^n a_i x^i, \text{ 则}$$

$$f[x_0, \dots, x_n] = a_n, f[x_0, \dots, x_{n+1}] = 0.$$

- Newton插值是指

$$f(x) = P_n(x) + f[x, x_0, \dots, x_n] \prod_{i=0}^n (x - x_i),$$

它与Lagrange插值多项式等价(插值多项式的唯一性), 其插值余项为

$$R_n(x) = f[x, x_0, \dots, x_n] \prod_{i=0}^n (x - x_i).$$

◦ **Hermite插值**

- **两点三次Hermite插值**(教材95页, 不过写得比较抽象)给定节点 $x_0 < x_1 < x_2$ 处的函数值和 x_1 处的导数值, 构造三次多项式 $H_3(x)$. 需要构造三个对应函数值的基函数 ϕ_0, ϕ_1, ϕ_2 和一个对应导数值的基函数 ψ , 它们要满足:

$$\phi_i(x_j) = \delta_{ij}, \quad \phi'_i(x_1) = 0, \quad \psi(x_j) = 0, \quad \psi'(x_1) = 1.$$

此时插值多项式即

$$H_3(x) = f(x_0)\phi_0(x) + f(x_1)\phi_1(x) + f(x_2)\phi_2(x) + f'(x_1)\psi(x).$$

若 $f \in C^4[x_0, x_2]$, 余项有表达式

$$R(x) = f(x) - H_3(x) = \frac{f^{(4)}(\xi)}{4!}(x-x_0)(x-x_1)^2(x-x_2), \quad \xi \in (x_0, x_2).$$

余项的证明方法, 常数 K 值法, 然后反复使用Rolle中值定理, 见Lagrange插值余项的证明.

- **三点三次Hermite插值**(教材上貌似没有)给定节点 $x_0 < x_1 < x_2$ 处的函数值和 x_1 处的导数值, 构造三次多项式 $H_3(x)$. 需要构造三个对应函数值的基函数 ϕ_0, ϕ_1, ϕ_2 和一个对应导数值的基函数 ψ , 它们要满足:

$$\phi_i(x_j) = \delta_{ij}, \quad \phi'_i(x_1) = 0, \quad \psi(x_j) = 0, \quad \psi'(x_1) = 1.$$

此时插值多项式即为

$$H_3(x) = f(x_0)\phi_0(x) + f(x_1)\phi_1(x) + f(x_2)\phi_2(x) + f'(x_1)\psi(x).$$

若 $f \in C^4[x_0, x_2]$, 余项有表达式

$$R(x) = f(x) - H_3(x) = \frac{f^{(4)}(\xi)}{4!}(x-x_0)(x-x_1)^2(x-x_2), \quad \xi \in (x_0, x_2).$$

余项的证明方法, 常数 K 值法, 然后反复使用Rolle中值定理, 见Lagrange插值余项的证明.

- **三次样条插值.** 给定区间 $[a, b]$ 上的一个划分

$a = x_0 < x_1 < \cdots < x_{n-1} < x_n = b$, 称 $S(x)$ 是关于前述划分的一个**三次多项式样条函数**, 如果 S 满足

(1) $S|_{[x_i, x_{i+1}]}$ ($i = 0, 1, \cdots, n-1$)是三次多项式, 即 S 在每个小区间上都是三次多项式;

(2) S 在每个内节点 x_i ($i = 1, 2, \cdots, n-1$)处具有**二阶连续导数**.

要确定三次样条函数, 每个小区间对应4个系数, n 个小区间共 $4n$ 个, 每个内节点提供3个连续条件, 共 $3(n-1)$ 个, 因此额外需要 $n+3$ 个附加条件. 对于**三次样条插值**, 需要 $n+1$ 个节点的函数值, 因此还需补充两个条件, 根据补充条件的不同, 有三种类型, 见101-102页.

- **最小二乘拟合.** 给定互异数据点 (x_i, y_i) ($i = 1, 2, \cdots, n$), 欲求 m 次多项式

$$p(x) := a_0 + a_1x + a_2x^2 + \cdots + a_mx^m \quad (m \leq n-1),$$

使得残差平方和 $Q(a_0, a_1, \cdots, a_m) := \sum_{i=1}^n [y_i - p(x_i)]^2$ 达到最小. 将 Q 视作 $a_0, \cdots, a_m$ 的多元函数, 由多元函数极值的必要条件知 a_j ($j = 0, 1, \cdots, m$)满足

$$\frac{\partial Q}{\partial a_j} = 2 \sum_{i=1}^n (p(x_i) - y_i) x_i^j = 0 \quad (j = 0, 1, \cdots, m),$$

即

$$\sum_{k=0}^n \left(\sum_{i=0}^m x_i^{j+k} \right) a_k = \sum_{i=0}^m x_i^j y_i \quad (j = 0, 1, \dots, n).$$

写成矩阵形式即为法方程组 $\mathbf{G}\mathbf{a} = \mathbf{b}$, 其中

$$\mathbf{G} := \begin{pmatrix} n & \sum x_i & \sum x_i^2 & \cdots & \sum x_i^m \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \cdots & \sum x_i^{m+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^m & \sum x_i^{m+1} & \sum x_i^{m+2} & \cdots & \sum x_i^{2m} \end{pmatrix}, \mathbf{a} = \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix}, \mathbf{b} = \begin{pmatrix} \sum y_i \\ \sum y_i x_i \\ \vdots \\ \sum y_i x_i^m \end{pmatrix}.$$

置

$$\mathbf{X} := \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \cdots & x_2^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{pmatrix},$$

则 $\mathbf{G} = \mathbf{X}^\top \mathbf{X}$, $\mathbf{b} = \mathbf{X}^\top \mathbf{y}$, 其中 $\mathbf{y} = (y_1, y_2, \dots, y_n)^\top$. 由线性代数知识知若 $n \leq m$, 点 $x_0, \dots, x_m$ 中至少 $n+1$ 个互异, 则法方程组的解存在且唯一. (120页定理1, 不过课本上证明得比较复杂, 考的概率比较低)

- **一般线性最小二乘拟合**, 原理和推导步骤和上面完全类似, 只是将基函数

$\{1, x, \dots, x^n\}$ 换成了 $n+1$ 个线性无关的函数 $\{\varphi_0, \varphi_1, \dots, \varphi_n\}$, 此时法方程组为

$\mathbf{G}\mathbf{a} = \mathbf{b}$, 其中

$$\mathbf{G} = \begin{pmatrix} \sum_{i=1}^n \varphi_0^2(x_i) & \sum_{i=1}^n \varphi_0(x_i)\varphi_1(x_i) & \sum_{i=1}^n \varphi_0(x_i)\varphi_2(x_i) & \cdots & \sum_{i=1}^n \varphi_0(x_i)\varphi_m(x_i) \\ \sum_{i=1}^n \varphi_1(x_i)\varphi_0(x_i) & \sum_{i=1}^n \varphi_1^2(x_i) & \sum_{i=1}^n \varphi_1(x_i)\varphi_2(x_i) & \cdots & \sum_{i=1}^n \varphi_1(x_i)\varphi_m(x_i) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n \varphi_m(x_i)\varphi_0(x_i) & \sum_{i=1}^n \varphi_m(x_i)\varphi_1(x_i) & \sum_{i=1}^n \varphi_m(x_i)\varphi_2(x_i) & \cdots & \sum_{i=1}^n \varphi_m^2(x_i) \end{pmatrix}$$

$$\mathbf{a} = (a_0, a_1, \dots, a_n)^\top,$$

$$\mathbf{b} = \left(\sum_{i=1}^n \varphi_0(x_i)y_i, \sum_{i=1}^n \varphi_1(x_i)y_i, \dots, \sum_{i=1}^n \varphi_m(x_i)y_i \right)^\top.$$

此时 $\mathbf{G}$ 可分解为 $\mathbf{G} = \mathbf{X}^\top \mathbf{X}$, 其中

$$\mathbf{X} := \begin{pmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_n(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \cdots & \varphi_n(x_m) \end{pmatrix}.$$

- **不相容矩阵的最小二乘解.** 对于不相容方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$, 记 $\mathbf{r} := \mathbf{b} - \mathbf{A}\mathbf{x}$, 则称使得 $\min_{\mathbf{x}} \|\mathbf{r}\|_2^2 = \min_{\mathbf{x}} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2$ 成立的 $\mathbf{x}$ 为不相容方程组的**最小二乘解**. 可以证明, $\mathbf{x}$ 为方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的最小二乘解的充分必要条件是满足法方程组

$$\mathbf{A}^\top \mathbf{A}\mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

- **最佳平方逼近.** 设 n 次最佳平方逼近多项式为

$$p(x) := c_0 + c_1x + \cdots + c_nx^n,$$

则其系数 $c_i (0 \leq i \leq n)$ 的求解方法是求解线性方程组

$$\begin{pmatrix} \langle 1, 1 \rangle & \langle 1, x \rangle & \langle 1, x^2 \rangle & \cdots & \langle 1, x^n \rangle \\ \langle x, 1 \rangle & \langle x, x \rangle & \langle x, x^2 \rangle & \cdots & \langle x, x^n \rangle \\ \langle x^2, 1 \rangle & \langle x^2, x \rangle & \langle x^2, x^2 \rangle & \cdots & \langle x^2, x^n \rangle \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \langle x^n, 1 \rangle & \langle x^n, x \rangle & \langle x^n, x^2 \rangle & \cdots & \langle x^n, x^n \rangle \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} \langle f, 1 \rangle \\ \langle f, x \rangle \\ \langle f, x^2 \rangle \\ \vdots \\ \langle f, x^n \rangle \end{pmatrix},$$

这里的内积定义为 $\langle g, h \rangle := \int_a^b g(x)h(x) dx$.

- 特别地, f 在 $[-1, 1]$ 上的二次最佳平方逼近多项式可以直接套用Legendre多项式的线性组合, 即

$$p(x) = c_0P_0(x) + c_1P_1(x) + c_2P_2(x),$$

其中系数 c_i 可由最佳平方逼近的定义求得, 即

$$c_n = \frac{\int_{-1}^1 f(x)P_n(x) dx}{\int_{-1}^1 P_n(x)P_n(x) dx} = \frac{2n+1}{2} \int_{-1}^1 f(x)P_n(x) dx, \quad n = 0, 1, 2.$$

其中

$$P_0(x) = 1, \quad P_1(x) = x, \quad P_2(x) = \frac{1}{2}(3x^2 - 1), \quad P_3(x) = \frac{1}{2}(5x^3 - 3x).$$

一般地, $[-1, 1]$ 上的 n 次Legendre多项式 $P_n(x)$ 可以通过导数形式定义为

$$P_n(x) := \frac{1}{2^n n!} \frac{d^n}{dx^n} (x^2 - 1)^n.$$

且有递推公式

$$P_{n+1}(x) = \frac{2n+1}{n+1}xP_n(x) - \frac{n}{n+1}P_{n-1}(x), \quad n \geq 1.$$

• 数值积分.

- 代数精度(一个求积公式具有 m 次代数精度的充分必要条件 $\iff$ 求积公式对 $x^k (k \in \{0, 1, \dots, m\})$ 精确成立, 而对 $k = m+1$ 不精确成立.)
- 插值型求积公式. 给定一组节点 $a \leq x_0 < x_1 < \dots < x_{n-1} < x_n \leq b$ 及函数 f 在这些节点上的值, 则有 f 的Lagrange插值多项式 $P_n(x) = \sum_{k=0}^n f(x_k)l_k(x)$, 此时数值积分公式为

$$I_n := \sum_{k=0}^n A_k f(x_k), \quad A_k := \int_a^b l_k(x) dx,$$

其余项为

$$R_n(f) = \int_a^b (f - P_n) = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^n (x - x_k) dx.$$

具有 $n+1$ 个求积节点的数值求积公式 $I_n := \sum_{k=0}^n A_k f(x_k)$ 是插值型求积公式 $\iff$ 该公式至少具有 n 次代数精度.

- Newton-Cotes公式, 此时求积节点等距分布. $n \leq 2$ 的Newton-Cotes公式分别为

$$T = \frac{b-a}{2} [f(a) + f(b)], \quad (n=1, \text{梯形公式});$$
$$S = \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right], \quad (n=2, \text{Simpson公式}).$$

其求积余项分别为

$$R_T = \int_a^b \frac{f''(\xi)}{2!} (x-a)(x-b) dx = -\frac{f''(\eta)}{12} (b-a)^3, \quad \eta \in [a, b];$$
$$R_S = -\frac{b-a}{180} \left(\frac{b-a}{2}\right)^4 f^{(4)}(\eta), \quad \eta \in [a, b].$$

梯形求积公式的余项的证明需要掌握, 即使用**第一积分中值定理**.

n (偶数)阶Newton-Cotes公式的代数精度为 $n+1$, n (奇数)阶Newton-Cotes公式的代数精度为 n .

Newton-Cotes公式的系数对于 $n \leq 7$ 都是正数, 此时Newton-Cotes公式是数值稳定的, 证明见教材151页, 需要掌握.

- 复化求积公式**(152页), 即先 n 等分, 在每个小区间上使用数值求积公式, 然后加起来. **注意课本上的公式是错误的!!!**

$$(1) \text{ 复化梯形. } T_n = \frac{h}{2} \left[f(a) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right], x_k = a + kh = a + k \frac{b-a}{n}.$$

求积余项为

$$I - T_n = \sum_{k=0}^{n-1} \left[-\frac{h^3}{12} f''(\eta_k) \right] = -\frac{h^2}{12} \frac{b-a}{n} \sum_{k=0}^{n-1} f''(\eta_k) = -\frac{b-a}{12} h^2 f''(\eta), \eta \in [a, b]$$

最后一个等号使用了**Darboux中值定理(即导函数具有介质性)**.

(2) 复化Simpson.

$$S_n = \frac{h}{6} \left[f(a) + 4 \sum_{k=0}^{n-1} f(x_{k+1/2}) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right], x_{k+1/2} = \frac{x_k + x_{k+1}}{2}. \text{ 求积}$$

余项类似推导.

- **Gauss求积.** n 个节点, 可适当选取节点达到 $2n-1$ 次代数精度, 也是最高代数精度, 此时求积公式称作Gauss求积公式, 求积节点称作Gauss点. 教材162页给出了两种特殊的Gauss求积公式, 即Gauss-Legendre求积公式. 若 $f \in C^{2n}([a, b])$, 则Gauss求积公式的求积余项为

$$R = \int_a^b f(x) dx - \sum_{k=1}^n A_k f(x_k) = \frac{f^{(2n)}(\xi)}{(2n)!} \int_a^b \prod_{i=1}^n (x - x_i)^2 dx, \quad \xi \in [a, b].$$

考试有可能考察Gauss公式的求积节点, 例如**教材176页第16题, 教材170页例10**, 涉及非线性方程求根.

- 给定了区间 $[a_1, b_1]$ 上的求积公式(常见为 $[0, 1], [-1, 1]$), 要求 $[a, b]$ 上的求积公式, 通用思路是待定一次函数 $y = kx + c$, 其中

$$\begin{cases} ka_1 + c = a, \\ kb_1 + c = b, \end{cases}$$

然后引入变量替换 $x =: kt + c$, 从而有

$$\sum_{k=1}^n A_k f(x_k) \approx \int_a^b f(x) dx = k \int_{a_1}^{b_1} f(kt + c) dt \approx \sum_{k=1}^n A_k f(kx_k + c).$$

特别注意引入变量替换后会多出出来的 k ! 比较特殊的求积公式会带有函数的导数信息, 如 $\sum_{k=1}^n A_k f(x_k) + \sum_{j=1}^m B_j f'(x_j)$, 此时作变量替换后导数值前面也会有系数的变化.

- **ODE数值解法.** 以下均设初值问题

$$\begin{cases} y' = f(x, y), & a < x \leq b; \\ y(a) = y_0. \end{cases}$$

- **局部截断误差.** 设 $y_n = y(x_n)$, 则 $T := y(x_{n+1}) - y_{n+1}$ 称为局部截断误差, 若 $T = O(h^{p+1})$, 则该数值方法具有 p 阶精度. 具体求法和例题见[\(数值分析典型例题\) 差分格式截断误差的首项的求法和绝对稳定区间](#).
- **绝对稳定区间.** 设要求解的微分方程为 $y' = f(x, y)$, 则令 $y' = f(x, y) = \lambda y (\lambda < 0)$, 在数值递推公式中将 $f(x, y)$ 全部替换成 λy , 然后令 $z := h\lambda$, 将原递推公式改写成 $y_{n+1} = R(z)y_n$ 的形式, 则绝对稳定区间为 $\{z : |R(z)| < 1\}$. 具体求法和例题见[\(数值分析典型例题\) 差分格式截断误差的首项的求法和绝对稳定区间](#).
- **Euler公式.** 设求解区间为 $[a, b]$ 被 N 等分, $h = \frac{b-a}{N}$, $x_n = a + nh (n = 0, 1, \dots, N)$, 则求解上面初值问题的公式

$$y_{n+1} = y_n + hf(x_n, y_n)$$

称作**Euler公式**, 它是显式公式, 其局部截断误差为

$$T_1 = \frac{h^2}{2} y''(\xi_n) (x_n < \xi_n < x_{n+1}), \text{ 它具有一阶精度, 绝对稳定区间为 } (-2, 0).$$

- **后退Euler公式** 即 $y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$, 它是隐式公式, 其局部截断误差为 $T_2 = -\frac{h^2}{2} y''(\eta_n) + O(h^3) = -\frac{h^2}{2} y''(\eta_n) (x_n < \eta_n < x_{n+1})$, 具有一阶精度, 绝对稳定区间为 $(-\infty, 0)$.
- **梯形公式** 即 $y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$, 其局部截断误差为 $T = -\frac{1}{12} h^3 y'''(x_n) + O(h^4)$, 具有二阶精度.

- **Runge-Kutta公式.** 二级Runge-Kutta公式

$$\begin{cases} k_1 = f(x_n, y_n), \\ k_2 = f(x_n + ah, y_n + ahk_1), \\ y_{n+1} = y_n + h(c_1 k_1 + c_2 k_2), \end{cases}$$

其中 a, c_1, c_2 待定. 其局部截断误差满足

$$T = [1 - (c_1 + c_2)]hy'(x_n) + \left(\frac{1}{2} - ac_2\right)h^2 y''(x_n) + O(h^3).$$

为了使 T 的阶数尽量高, 需要满足 $\begin{cases} c_1 + c_2 = 1, \\ ac_2 = 1/2, \end{cases}$ 此时继续展开 k_2 , T 中 h^3 的系数就不为 0.

- **常用的函数展开以及二元Taylor公式**(重要!) 对于Runge-Kutta等**隐式求解**公式, 如由于 f 的自变量中包含了未知的 y , 如

$$y_{n+1} = y_n + hf\left(x_n + \frac{h}{2}, y_n + \frac{h}{2}f_n\right),$$

此时不能简单地把 f 换成 y' , 必须使用**二元函数的Taylor展开**:

$$\begin{aligned} & f(x_n + \Delta x, y_n + \Delta y) \\ &= f + f_x \Delta x + f_y \Delta y + \frac{1}{2} (f_{xx} (\Delta x)^2 + 2f_{xy} \Delta x \Delta y + f_{yy} (\Delta y)^2) + \cdots \end{aligned}$$

展开后, 再利用全导数公式($y'' = f_x + f f_y$, $y''' = f_{xx} + 2f f_{xy} + f^2 f_{yy} + f_y y''$ 等)将偏导数凑成 y'', y''' .

- 高阶方程转化为一阶方程. 考虑初值问题

$$\begin{cases} u' = \varphi(x, u, v), & u(x_0) = u_0; \\ v' = \psi(x, u, v), & v(x_0) = v_0. \end{cases}$$

引入记号 $\mathbf{y}(x) := (u, v)^\top$, $\mathbf{f}(x, \mathbf{y}) = (\varphi, \psi)^\top$, $\mathbf{y}_0 = (u_0, v_0)^\top$, 则原初值问题可改写为

$$\begin{cases} \mathbf{y}' = \mathbf{f}(x, \mathbf{y}), \\ \mathbf{y}(x_0) = \mathbf{y}_0. \end{cases}$$